

PENERAPAN ALGORITMA RANDOM FOREST DALAM MEMPREDIKSI KESELAMATAN PENUMPANG TITANIC

Disusun Untuk Memenuhi Tugas Akhir
Mata Kuliah Pengantar Data Sains



Dosen Pengampu:

Faroh Ladayya, M.Si.

Endang Yuliani, S.Mat., M.Si.

Disusun oleh:

Shafa Fatimah Az zahra (NIM 1314623062)

**UNIVERSITAS NEGERI JAKARTA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
2025**

DAFTAR ISI

DAFTAR ISI	2
BAB I PENDAHULUAN	3
1.1 Latar Belakang.....	3
2.2 Tujuan	3
BAB II METODOLOGI PENELITIAN	4
2.1 Jenis dan Sumber Data.....	4
2.2 Variabel Penelitian.....	4
2.3 Tahapan Analisis Data	5
BAB III HASIL DAN PEMBAHASAN	7
3.1 Hasil <i>Preprocessing</i> Data.....	7
3.2 Hasil <i>Exploratory Data Analysis</i>	7
3.3 Pemodelan Random Forest terhadap Data Pelatihan	10
3.4 Evaluasi Kinerja Model Random Forest.....	10
3.5 Pemodelan Random Forest terhadap Data Prediksi	11
3.6 Hasil <i>Feature Importance</i>	12
BAB IV KESIMPULAN	14
DAFTAR PUSTAKA	15

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pemodelan data merupakan proses penting dalam data science yang bertujuan untuk membangun model prediktif berdasarkan data historis. Salah satu pendekatan yang paling umum digunakan adalah *supervised learning*, yaitu metode pembelajaran mesin yang menggunakan data berlabel untuk melatih model agar mampu melakukan prediksi pada data baru. Dalam konteks *supervised learning*, klasifikasi digunakan untuk memetakan suatu objek ke dalam kelas tertentu berdasarkan karakteristiknya. Dataset Titanic merupakan contoh klasik dari permasalahan klasifikasi biner, di mana model digunakan untuk memprediksi apakah seorang penumpang selamat atau tidak berdasarkan atribut demografis dan sosial ekonomi mereka (Kuhn & Johnson, 2020; Géron, 2022).

Kemampuan model klasifikasi dalam mengenali pola dari data memungkinkan pengambilan keputusan yang lebih akurat dan berbasis data. Menurut Aggarwal (2020), kualitas hasil klasifikasi sangat bergantung pada proses eksplorasi data, pemilihan fitur prediktor, serta algoritma yang digunakan. Oleh karena itu, eksplorasi data (*Exploratory Data Analysis*) menjadi tahap awal yang krusial untuk memahami distribusi data serta potensi masalah seperti data hilang dan outlier sebelum membangun model klasifikasi.

Salah satu algoritma *supervised learning* yang banyak digunakan untuk klasifikasi adalah Random Forest. Random Forest merupakan metode ensemble yang membangun banyak pohon keputusan dan menggabungkan hasil prediksinya untuk meningkatkan akurasi dan stabilitas model. Algoritma ini dikenal mampu menangani data berdimensi tinggi, bersifat robust terhadap outlier, serta dapat mengurangi risiko overfitting dibandingkan pohon keputusan tunggal (Breiman, 2001; Hastie, Tibshirani, & Friedman, 2021). Selain itu, Random Forest menyediakan informasi *feature importance* yang membantu dalam mengidentifikasi variabel-variabel yang paling berpengaruh terhadap hasil prediksi, sehingga sangat bermanfaat dalam analisis interpretatif.

Berdasarkan karakteristik tersebut, penggunaan Random Forest pada dataset Titanic menjadi relevan untuk mempelajari penerapan *supervised learning* dalam konteks klasifikasi. Dengan demikian, studi ini tidak hanya bertujuan untuk menghasilkan prediksi, tetapi juga untuk meningkatkan pemahaman konseptual mengenai metode klasifikasi dalam *data science* modern (Géron, 2022).

2.2 Tujuan

1. Melakukan eksplorasi data (EDA) untuk memahami karakteristik data dan menentukan variabel prediktor yang relevan.
2. Membangun model klasifikasi menggunakan algoritma Random Forest dan mengevaluasi kinerjanya.
3. Menggunakan model yang telah dilatih untuk memprediksi status keselamatan penumpang pada dataset prediksi.
4. Menginterpretasikan hasil pemodelan melalui analisis *feature importance*.

BAB II

METODOLOGI PENELITIAN

2.1 Jenis dan Sumber Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang berasal dari dataset Titanic. Dataset terdiri dari dua bagian utama, yaitu:

1. Dataset Pelatihan (*Pelatihan Dataset*)

Dataset ini berisi data penumpang Titanic beserta variabel target Survived yang menunjukkan status keselamatan penumpang. Dataset ini digunakan untuk melatih dan mengevaluasi model klasifikasi.

2. Dataset Prediksi (*Prediction Dataset*)

Dataset ini memiliki struktur variabel yang sama dengan dataset pelatihan, namun tidak memiliki variabel Survived. Dataset ini digunakan untuk menghasilkan prediksi status keselamatan berdasarkan model yang telah dilatih.

Berikut Adalah variabel-variabel yang ada pada dataset Titanic:

Variabel	Jenis Data	Deskripsi
PassengerId	Numerik	Nomor Penumpang
Survived	Kategorik	Status keselamatan penumpang
Sex	Kategorik	Jenis kelamin penumpang
Name	Teks (string)	Nama penumpang
Age	Numerik	Umur penumpang
Pclass	Ordinal	Kelas tiket (1, 2, 3)
Fare	Numerik	Harga tiket
SibSp	Numerik	Jumlah saudara/pasangan
Parch	Numerik	Jumlah orang tua/anak
Ticket	Numerik	Nomor tiket penumpang
Cabin	Teks (string)	Nomor kabin penumpang
Embarked	Kategorik	Pelabuhan keberangkatan dengan kode 0 = Cherbourg, 1 = Queenstown, 2 = Southampton

Tabel 1. Variabel Dataset

2.2 Variabel Penelitian

2.2.1 Variabel Target dan Prediktor

Variabel dalam penelitian ini dibedakan menjadi variabel target, variabel prediktor utama, dan variabel hasil rekayasa fitur (*feature engineering*). Variabel target merupakan variabel yang menjadi fokus prediksi dalam model klasifikasi, yaitu variabel Survived yang menunjukkan status keselamatan penumpang titanic.

Variabel Survived hanya digunakan pada tahap pelatihan dan evaluasi model. Sedangkan variabel prediktor yang digunakan untuk memprediksi variabel target dalam penelitian ini adalah sebagai berikut:

Variabel	Jenis Data	Deskripsi
Sex	Kategorik	Jenis kelamin penumpang
Age	Numerik	Umur penumpang
Pclass	Ordinal	Kelas tiket (1, 2, 3)
Fare	Numerik	Harga tiket

SibSp	Numerik	Jumlah saudara/pasangan
Parch	Numerik	Jumlah orang tua/anak
Embarked	Kategorik	Pelabuhan keberangkatan
FamilySize	Numerik	Jumlah seluruh anggota keluarga yang ikut serta
IsAlone	Kategorik	1: Penumpang bepergian sendiri 0: Penumpang tidak sendiri

Tabel 1. Variabel Prediktor

Variabel PassengerId, Name, Ticket, dan Cabin tidak digunakan sebagai prediktor karena tidak memiliki hubungan langsung atau konsisten dengan status keselamatan, namun tetap disimpan untuk keperluan identifikasi dan pelaporan hasil.

Untuk meningkatkan kemampuan model dalam menangkap pola data, dilakukan rekayasa fitur dengan membentuk variabel prediktor baru, yaitu:

1. FamilySize

Variabel ini dibentuk dari:

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

Variabel ini merepresentasikan jumlah total anggota keluarga yang ikut serta dalam perjalanan.

2. IsAlone

Variabel indikator yang menunjukkan apakah penumpang bepergian sendiri:

Kedua variabel ini digunakan untuk menangkap aspek sosial penumpang yang tidak sepenuhnya tercermin oleh variabel SibSp dan Parch secara terpisah. Variabel SibSp dan Parch tetap digunakan sebagai prediktor walaupun ada variabel FamilySize dan IsAlone. Random Forest relatif robust terhadap multikolinearitas sehingga tidak menjadi masalah. Model akan secara otomatis menyesuaikan kontribusi masing-masing variabel.

2.3 Tahapan Analisis Data

2.3.1 Preprocessing Data

Tahap ini bertujuan untuk memastikan data berada dalam kondisi siap pakai untuk pemodelan. Proses yang dilakukan meliputi pemeriksaan struktur data, penanganan *missing values* dan transformasi variabel kategorik.

2.3.2 Exploratory Data Analysis (EDA)

EDA dilakukan untuk memahami karakteristik data dan hubungan antar variabel. Analisis yang dilakukan meliputi:

1. Analisis statistik deskriptif
2. Visualisasi distribusi variabel menggunakan histogram
3. Korelasi Data
4. Deteksi outlier menggunakan metode *Interquartile Range* (IQR)

Hasil EDA digunakan sebagai dasar dalam pemilihan variabel prediktor dan strategi *preprocessing*.

2.3.3 Pemodelan Random Forest terhadap Data Pelatihan

Pemodelan dilakukan menggunakan algoritma Random Forest, yaitu metode ensemble berbasis pohon keputusan yang menggabungkan banyak pohon untuk meningkatkan akurasi dan mengurangi risiko *overfitting*. Random Forest bekerja dengan

membangun sejumlah pohon keputusan pada subset data secara acak dan kemudian menggabungkan hasil prediksi setiap pohon untuk menghasilkan keputusan akhir (voting mayoritas). Kelebihan metode ini adalah mampu menangani data yang memiliki variabel numerik dan kategorik, serta relatif robust terhadap *outlier* dan data yang tidak seimbang.

Untuk memperoleh performa terbaik, dilakukan optimasi *hyperparameter* menggunakan RandomizedSearchCV. Pendekatan ini dipilih karena memungkinkan pencarian kombinasi parameter yang luas secara efisien dibanding grid search, tanpa harus mencoba semua kemungkinan kombinasi. RandomizedSearchCV melakukan sampling acak dari ruang hyperparameter dan mengevaluasi setiap kombinasi menggunakan *cross-validation* (5-fold). Dengan cara ini, model diuji pada berbagai konfigurasi untuk menemukan kombinasi *hyperparameter* yang memberikan akurasi terbaik.

2.3.4 Evaluasi kinerja Model Random Forest

Evaluasi model dilakukan menggunakan data uji dengan metrik evaluasi yang terdiri dari *Accuracy* untuk mengukur ketepatan prediksi secara keseluruhan, *Confusion Matrix* untuk melihat distribusi prediksi benar dan salah, serta *Precision*, *Recall*, dan *F1-score* untuk menilai performa klasifikasi secara lebih rinci.

2.3.5 Pemodelan Random Forest terhadap Data Prediksi

Model Random Forest yang telah dilatih selanjutnya digunakan untuk memprediksi status keselamatan penumpang pada dataset prediksi. Hasil prediksi digabungkan dengan data identitas penumpang dan disajikan dalam bentuk tabel.

2.3.6 Feature Importance

Interpretasi model dilakukan menggunakan *feature importance* dari Random Forest. Analisis ini digunakan untuk mengidentifikasi variabel yang paling berpengaruh terhadap prediksi keselamatan penumpang dan memberikan pemahaman yang lebih mendalam mengenai faktor-faktor penentu keselamatan.

Nilai feature importance diperoleh menggunakan metode Mean Decrease in Impurity (MDI) yang dihasilkan oleh algoritma Random Forest. Metode ini mengukur tingkat kepentingan suatu fitur berdasarkan rata-rata penurunan impurity (Gini Index) yang dihasilkan oleh fitur tersebut pada seluruh pohon keputusan dalam model. Semakin besar nilai penurunan impurity, semakin besar kontribusi fitur tersebut dalam proses prediksi.

BAB III

HASIL DAN PEMBAHASAN

3.1 Hasil *Preprocessing* Data

Tahap preprocessing dilakukan untuk memastikan data berada dalam kondisi yang layak dan optimal untuk proses analisis serta pemodelan klasifikasi. Hasil pemeriksaan awal menunjukkan bahwa penumpang terdapat sebanyak 891 orang pada data pelatihan dan data prediksi terdiri dari 418 penumpang.

3.1.1 Penanganan Data Hilang

Hasil pemeriksaan struktur data pelatihan menunjukkan bahwa terdapat *missing value* pada variabel *age* sebanyak 177 data dan variabel *Embarked* sebanyak 2 data. Selain itu, pada data prediksi juga terdapat *missing value* pada variabel *age* sebanyak 86 data dan *fare* sebanyak 1 data. Penanganan dilakukan dengan mengisi *missing value* *Embarked* menggunakan nilai modus, *Age* dan *fare* menggunakan nilai median. Pendekatan ini dipilih karena median lebih robust terhadap outlier, sementara modus merepresentasikan kategori yang paling dominan. Setelah tahap ini, seluruh variabel prediktor tidak lagi mengandung data hilang.

3.1.2 Transformasi Variabel Kategorik

Agar dapat diproses oleh algoritma Random Forest, variabel kategorik dikonversi ke bentuk numerik. Variabel *Sex* dan *Embarked* diubah menggunakan teknik encoding sehingga seluruh fitur berada dalam format numerik tanpa menghilangkan makna kategorinya

3.1.3 Feature Engineering

Pada tahap rekayasa fitur, dibentuk dua variabel baru, yaitu:


- *FamilySize*, yang merepresentasikan jumlah total anggota keluarga penumpang
- *IsAlone*, yang menunjukkan apakah penumpang bepergian sendiri atau tidak

Pembentukan fitur ini bertujuan untuk menangkap kondisi sosial penumpang secara lebih ringkas dan informatif dibandingkan penggunaan variabel *SibSp* dan *Parch* secara terpisah.


3.2 Hasil Exploratory Data Analysis

EDA dilakukan untuk memahami karakteristik data dan hubungan antara variabel prediktor dengan status keselamatan penumpang.

3.2.1 Distribusi Data




Grafik histogram berdasarkan jenis kelamin menunjukkan perbedaan yang sangat jelas antara tingkat keselamatan penumpang laki-laki dan perempuan. Mayoritas penumpang laki-laki berada pada kategori tidak selamat (Survived = 0), sedangkan sebagian besar penumpang perempuan justru berada pada kategori selamat (Survived = 1). Pola ini mengindikasikan adanya prioritas evakuasi, yang secara historis dikenal dengan prinsip “women and children first”. Selain itu, grafik. Temuan ini menunjukkan bahwa variabel Sex, Age dan Pclass merupakan variabel prediktor yang relevan dalam model penelitian ini.



Berdasarkan visualisasi jumlah penumpang menurut pelabuhan keberangkatan (Embarked) dan status keselamatan, terlihat bahwa mayoritas penumpang berasal dari pelabuhan dengan kode 2, baik pada kelompok selamat maupun tidak selamat. Pada pelabuhan ini, jumlah penumpang yang tidak selamat lebih tinggi dibandingkan yang selamat, yang mengindikasikan adanya perbedaan tingkat keselamatan antar pelabuhan keberangkatan. Sementara itu, pelabuhan dengan kode 0 dan 1 memiliki jumlah penumpang yang relatif lebih sedikit, dengan proporsi penumpang selamat yang lebih tinggi pada pelabuhan kode 0 dibandingkan pelabuhan lainnya.

Pada visualisasi berdasarkan kelas penumpang (Pclass) dan pelabuhan keberangkatan, terlihat bahwa penumpang kelas 3 mendominasi jumlah keberangkatan dari semua pelabuhan, terutama dari pelabuhan dengan kode 2 yaitu pelabuhan Southampton. Sebaliknya, penumpang kelas 1 jumlahnya relatif lebih sedikit, namun tersebar di berbagai pelabuhan. Pola ini menunjukkan bahwa sebagian besar penumpang berasal dari kelas ekonomi bawah dan paling banyak berangkat dari Pelabuhan Southampton, yang berpotensi memengaruhi peluang keselamatan penumpang.

3.2.1 Korelasi Data



Berdasarkan heatmap korelasi, variabel Sex menunjukkan korelasi negatif paling kuat terhadap Survived ($-0,54$), yang mengindikasikan bahwa jenis kelamin berpengaruh signifikan terhadap peluang keselamatan penumpang, di mana penumpang laki-laki cenderung memiliki peluang selamat yang lebih rendah. Selain itu, variabel Pclass juga memiliki korelasi negatif sedang dengan Survived ($-0,34$), sedangkan Fare menunjukkan korelasi positif ($0,26$), yang berarti penumpang dengan kelas lebih tinggi dan harga tiket lebih mahal cenderung memiliki peluang keselamatan yang lebih besar.

Variabel Age, SibSp, Parch, dan Embarked menunjukkan korelasi yang relatif lemah terhadap Survived, sehingga pengaruhnya secara linear tidak terlalu dominan. Selain itu, terdapat korelasi antar variabel independen, seperti hubungan negatif antara Fare dan Pclass ($-0,55$) serta korelasi positif antara SibSp dan Parch ($0,41$). Secara keseluruhan, hasil korelasi ini mendukung temuan pemodelan Random Forest bahwa variabel Sex, Pclass, dan Fare merupakan faktor utama dalam menentukan keselamatan penumpang Titanic.

3.2.2 Statistik Deskriptif

Statistik	Survived	Pclass	Age	FamilySize	Fare
Count	891.000000	891.000000	891.000000	891.000000	891.000000
Mean	0.383838	2.308642	29.361582	1.904602	32.204208
Std	0.486592	0.836071	13.019697	1.613459	49.693429
Min	0.000000	1.000000	0.420000	1.000000	0.000000
Max	1.000000	3.000000	80.000000	11.000000	512.329200

Tabel 3. Statistik Deskriptif

Berdasarkan statistik deskriptif, mayoritas penumpang berumur muda hingga dewasa muda (median 27 tahun) dengan variasi cukup luas ($0,17-76$ tahun), dan mayoritas memiliki keluarga kecil di kapal (FamilySize median = 1, maksimum 11). dan membayar tarif tiket rendah hingga menengah (median 14,45) meskipun terdapat beberapa tiket sangat mahal (maksimum 512,33). Distribusi umur dan tarif tiket miring ke kanan, sedangkan jumlah keluarga mayoritas nol, menunjukkan peluang survival bisa dipengaruhi oleh faktor usia, ukuran keluarga, dan kelas/tarif tiket.

3.2.3 Outlier

Berdasarkan hasil deteksi outlier menggunakan metode IQR, terdapat sejumlah *outlier* di beberapa variabel.

Variabel	Jumlah Outlier
Age	66
SibSp	46
Parch	213
Fare	116

Tabel 4. Outlier pada Data Pelatihan

Semua *outlier* ini merupakan data nyata yang menggambarkan kondisi penumpang sehingga sebaiknya tidak dihapus saat menggunakan Random Forest. *Outlier* ini justru

membawa informasi penting terkait karakteristik penumpang. Selain itu, Random Forest juga relatif robust terhadap data *outlier*.

3.3 Pemodelan Random Forest terhadap Data Pelatihan

Dataset pelatihan dibagi menjadi dua bagian, yaitu 80% data latih, digunakan untuk melatih model dan 20% data uji, digunakan untuk mengevaluasi performa model. Pembagian ini bertujuan untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Pemodelan dilakukan menggunakan algoritma Random Forest karena kemampuannya dalam mengurangi overfitting dan menghasilkan performa yang stabil. Untuk memperoleh parameter yang optimal, dilakukan optimasi hyperparameter menggunakan RandomizedSearchCV dengan skema *5-fold cross validation* dan sebanyak 30 kombinasi parameter, sehingga total dilakukan 150 proses pelatihan model.

Hasil optimasi menunjukkan bahwa parameter terbaik diperoleh pada nilai $n_estimators = 100$, $max_depth = 5$, $min_samples_split = 5$, $min_samples_leaf = 2$, $max_features = 'sqrt'$, dan $bootstrap = False$. Kombinasi parameter tersebut menghasilkan skor akurasi rata-rata *cross-validation* sebesar 0,83.

3.4 Evaluasi Kinerja Model

Model terbaik kemudian dievaluasi menggunakan data uji dan menghasilkan akurasi sebesar 0,80, yang berarti model mampu mengklasifikasikan data dengan benar sebesar 80% dari total data uji. Nilai ini mengindikasikan bahwa model memiliki performa klasifikasi yang cukup baik dan mampu melakukan generalisasi terhadap data yang belum pernah dilihat sebelumnya. Berikut adalah hasil *confusion matrix* dari model:

Aktual	Hasil Prediksi		Jumlah Baris
	0 (Tidak selamat)	1 (Selamat)	
0 (Tidak selamat)	93	12	105
1 (Selamat)	23	51	74
Jumlah Kolom	116	63	179

Tabel 5. *Confusion Matrix*

Berdasarkan *confusion matrix*, model berhasil mengklasifikasikan dengan benar 93 dari 105 penumpang yang tidak selamat dan 51 dari 74 penumpang yang selamat. Hal ini menunjukkan bahwa model memiliki kemampuan yang baik dalam mengenali kelas tidak selamat. Namun, masih terdapat 12 penumpang tidak selamat yang salah diprediksi sebagai selamat dan 23 penumpang selamat yang salah diprediksi sebagai tidak selamat. Kondisi ini menunjukkan bahwa model cenderung lebih sulit dalam mengidentifikasi penumpang yang selamat dibandingkan yang tidak selamat, meskipun secara keseluruhan performa klasifikasi model tergolong baik.

Evaluasi juga dilakukan melalui *classification report* dari model yang hasilnya sebagai berikut:

Kelas	Precision	Recall	F1-score	Support
0	0.80	0.89	0.84	105

1	0.81	0.69	0.74	74
Accuracy			0.80	179
Macro avg	0.81	0.79	0.79	179
Weighted avg	0.80	0.80	0.80	179

Tabel 6. Classification Report

Berdasarkan metrik evaluasi, nilai *precision* untuk kelas 0 dan kelas 1 masing-masing sebesar 0,80 dan 0,81, yang menunjukkan tingkat ketepatan prediksi yang tinggi. Namun, nilai *recall* pada kelas 1 sebesar 0,69 lebih rendah dibandingkan kelas 0 sebesar 0,89, yang mengindikasikan bahwa model masih kurang optimal dalam mendeteksi seluruh data pada kelas 1. Nilai *F1-score* menunjukkan performa model yang lebih baik pada kelas 0 (0,84) dibandingkan kelas 1 (0,74). Meskipun demikian, nilai *weighted average F1-score* sebesar 0,80 menunjukkan bahwa secara keseluruhan model memiliki kinerja yang stabil dan layak digunakan, dengan catatan masih terdapat peluang peningkatan performa dalam klasifikasi kelas 1.



3.5 Pemodelan Random Forest terhadap Data Prediksi



Model Random Forest terbaik yang diperoleh dari proses optimasi kemudian digunakan untuk melakukan prediksi pada data prediksi titanic. Proses prediksi ini bertujuan untuk mengklasifikasikan setiap observasi ke dalam kelas selamat (1) atau tidak selamat (0) berdasarkan pola yang dipelajari dari data pelatihan. Berdasarkan prediksi survival dari dataset Titanic mendapat hasil sebagai berikut:

Survived	Count
0 (Tidak Selamat)	283
1 (Selamat)	135

Tabel 7. Hasil Prediksi Dataset Titanic

Secara keseluruhan dari 418 penumpang yang di prediksi, 135 diprediksi selamat dan 283 tidak selamat, sesuai dengan pola historis Titanic. Setelah diprediksi, dilakukan visualisasi data prediksi sebagai berikut:





Berdasarkan visualisasi prediksi survival dari dataset Titanic:

1. Survival vs Jenis Kelamin

Mayoritas perempuan (Sex=0) diprediksi selamat (126 orang), sedangkan hampir semua laki-laki (Sex=1) diprediksi tidak selamat (257 orang). Hal ini konsisten dengan sejarah Titanic dan distribusi data pelatihan bahwa perempuan memiliki peluang selamat lebih tinggi dibanding laki-laki.

2. Survival vs Kelas Tiket (Pclass)

Penumpang kelas 1 diprediksi selamat hampir setara dengan yang tidak selamat (52 selamat vs 55 tidak selamat). Sedangkan penumpang kelas 2 dan 3 mayoritas tidak selamat (167 tidak selamat vs 51 selamat). Ini menunjukkan kelas tiket berpengaruh signifikan terhadap survival, dimana kelas lebih tinggi cenderung lebih aman.

3. Survival vs FamilySize

Penumpang dengan FamilySize 1 (sendirian) sebagian besar tidak selamat. Penumpang dengan FamilySize 2–3 memiliki peluang selamat lebih tinggi (misal FamilySize=3, 35 selamat vs 22 tidak selamat). Sedangkan untuk ukuran keluarga yang sangat besar (>4), prediksi selamat relatif sedikit. Hal ini mengindikasikan ukuran keluarga sedang cenderung lebih aman, sedangkan penumpang yang sendirian atau terlalu besar berisiko lebih tinggi.

4. Survival vs *Port of Embarkation*

Berdasarkan visualisasi, dapat dilihat kalau proporsi penumpang tidak selamat dengan pelabuhan keberangkatan Southampton lebih tinggi dibanding 2 pelabuhan lainnya. Hal tersebut dapat terjadi karena penumpang yang berangkat dari Queenstown dan Cherbourg lebih sedikit dan biasanya penumpang dengan kelas penumpang tinggi, hal ini sejalan dengan visualisasi pada data eksplorasi sebelumnya bahwa penumpang dengan kelas yang lebih rendah proporsi tidak selamatnya lebih tinggi.

3.6 Hasil *Feature Importance*


Berikut hasil feature Importance yang dihasilkan oleh algoritma Random Forest menggunakan metode Mean Decrease in Impurity (MDI):

Variabel	Nilai Feature Importance
Sex	0.513062
Pclass	0.154923

Fare	0.121287
Age	0.089035
FamilySize	0.053837
SibSp	0.022467
Embarked	0.021631
IsAlone	0.014468
Parch	0.009290

Tabel 1. Feature Importance

Berdasarkan hasil *feature importance* dari model Random Forest, variabel Sex memiliki kontribusi paling besar dalam menentukan keselamatan penumpang Titanic dengan nilai *importance* sebesar 0,51. Hal ini menunjukkan bahwa jenis kelamin merupakan faktor dominan, di mana penumpang perempuan memiliki peluang keselamatan yang jauh lebih tinggi dibandingkan penumpang laki-laki. Temuan ini sejalan dengan kebijakan evakuasi “women and children first” yang diterapkan pada peristiwa Titanic.



Variabel Pclass dan Fare menempati urutan selanjutnya dengan nilai *importance* masing-masing sebesar 0,15 dan 0,12. Kedua variabel ini mencerminkan status sosial ekonomi penumpang, di mana penumpang kelas atas dan dengan harga tiket yang lebih mahal cenderung memiliki akses yang lebih baik terhadap fasilitas keselamatan. Variabel Age juga memiliki pengaruh yang cukup signifikan (0,09), yang menunjukkan bahwa usia turut memengaruhi peluang keselamatan, meskipun tidak sekuat jenis kelamin dan kelas penumpang.

Sementara itu, variabel terkait struktur keluarga seperti FamilySize, SibSp, Parch, dan IsAlone memiliki kontribusi yang relatif lebih kecil. Hal ini mengindikasikan bahwa meskipun faktor keberadaan keluarga berpengaruh terhadap keselamatan, dampaknya tidak sebesar faktor demografis dan ekonomi. Variabel Embarked memiliki nilai *importance* yang rendah, sehingga pelabuhan keberangkatan tidak menjadi faktor utama dalam penentuan keselamatan penumpang. Secara keseluruhan, hasil ini menunjukkan bahwa model Random Forest lebih banyak mengandalkan faktor jenis kelamin, kelas penumpang, dan kondisi ekonomi dalam memprediksi keselamatan penumpang Titanic.

BAB IV

KESIMPULAN

Berdasarkan analisis data Titanic, keselamatan penumpang dipengaruhi terutama oleh jenis kelamin, kelas tiket, dan status ekonomi. Perempuan dan penumpang kelas atas memiliki peluang selamat lebih tinggi, sedangkan laki-laki dan penumpang kelas ekonomi rendah lebih berisiko. Faktor usia, ukuran keluarga, dan pelabuhan keberangkatan memiliki pengaruh lebih kecil, meskipun ukuran keluarga sedang cenderung meningkatkan peluang keselamatan dibanding penumpang yang sendirian atau dengan keluarga besar.

Pemodelan menggunakan algoritma Random Forest menunjukkan hasil yang baik dengan akurasi 80% pada data uji. Model mampu mengenali pola survival dengan stabil, meskipun kelas penumpang yang selamat memiliki *recall* lebih rendah dibanding kelas tidak selamat. Hasil evaluasi melalui *confusion matrix* dan *classification report* menunjukkan bahwa model efektif dalam memprediksi keselamatan, terutama untuk penumpang yang tidak selamat.

Analisis *feature importance* berdasarkan pemodelan prediksi dataset Titanic menegaskan bahwa faktor dominan dalam menentukan keselamatan adalah jenis kelamin, kelas penumpang, dan tarif tiket. Faktor struktural seperti keberadaan keluarga dan pelabuhan keberangkatan memiliki kontribusi lebih kecil. Secara keseluruhan, model Random Forest berhasil menangkap pola historis Titanic dan menunjukkan bahwa aspek demografis dan ekonomi lebih berpengaruh dibanding faktor lain dalam menentukan peluang survival penumpang.

DAFTAR PUSTAKA

- Aggarwal, C. C. (2020). *Data Mining: The Textbook* (2nd ed.). Springer.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2021). *The Elements of Statistical Learning* (2nd ed.). Springer.
- Kuhn, M., & Johnson, K. (2020). *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.